

XIX CONGRESO DE METODOLOGÍA DE LAS
CIENCIAS SOCIALES Y DE LA SALUD
AEMCCO
7-9 JULIO 2026 · UNIVERSIDAD DE ALMERÍA

Que no te engañe el azar

Cómo impacta la aleatoriedad en el diseño de redes neuronales

Enrique Heredia-Aguado · Alejandro Rujano · David Valiente · Arturo Gil

Universidad Miguel Hernández de Elche · UNED

Esta presentación:



EL PROBLEMA

La aleatoriedad afecta a los resultados

Dos ejecuciones «iguales» acaban en sitios distintos.

- ▶ Distintos datos generados en nuestra simulación.
- ▶ Figuras con aspecto diferente.
- ▶ Algoritmos de optimización o de búsqueda
- ▶ Modelos de aprendizaje con diferente resultado.

Esta presentación:



EL PROBLEMA

¿Cuánto de lo que concluimos depende del azar?

Entrenar un modelo de aprendizaje tiene mecanismos de aleatoriedad que pueden influir en la inicialización, carga de datos, entrenamiento o funcionamiento.

Diferentes configuraciones (hiperparámetros), que no modifican el modelo en sí, también pueden afectar a los resultados o al proceso de aprendizaje.

Esta presentación:



EL PROBLEMA

La semilla toca la inicialización y la optimización

```
# fijamos la semilla y respiramos tranquilos...  
set.seed(42)  
modelo <- entrenar(datos)
```

Reproducible, sí. Pero, ¿controlamos lo que esa semilla **esconde**?

Esta presentación:



Replicación de Visión por Computador

The Impact of Performance Variability on Neural Network Evaluation and its Implications for Model Design

Enrique Heredia-Aguado^{a,*}, Alejandro Rujano^b, Mónica Ballesta^a, David Valiente^a and Arturo Gil^a

^a *University Institute for Engineering Research, Miguel Hernández University, Avda. de la Universidad s/n, Elche, 03202, Alicante, Spain*

^b *National Distance Education University, Bravo Murillo, 38, Madrid, 28015, Madrid, Spain*


ARTICLE INFO

ABSTRACT

¿Replicación sobre modelos de aprendizaje en ciencias del comportamiento?

TRABAJO PREVIO

Una varianza estrecha que sí importa



5 parametrizaciones × 400 semillas = **2000 entrenos**: el techo es **99.66 %**. El 99.75 % reportado no lo alcanza ninguna receta estándar.

ARTÍCULO Baldominos, A., Sáez, Y., & Isasi, P. (2019). A survey of handwritten character recognition with MNIST and EMNIST. *Applied Sciences*, 9(15), 3169.

¿Qué hay en el ámbito de las ciencias del comportamiento?

¿ ... ?



METODOLOGÍA

CPC18: predecir decisiones humanas bajo riesgo

Varios modelos de la bibliografía · N entrenamientos cada uno.

Simulaciones:

- ▶ **Bootstrap:** remuestreo sobre la muestra.
- ▶ **Monte Carlo:** remuestreo sobre la distribución estimada.

Análisis:

- ▶ ANOVA y descomposición de varianza.

CASO 1: COMPARANDO MODELOS

Dos modelos, N ejecuciones

BourginMLP

VS

SparseMLP

Cada uno, **800 entrenamientos** con semillas distintas → una distribución de rendimiento por modelo


¿Podemos decir cuál gana con **un solo entrenamiento**?

CONGRESO Bourgin, D. D., Peterson, J. C., Reichman, D., Russell, S. J., & Griffiths, T. L. (2019). Cognitive model priors for predicting human decisions. *Proceedings of the 36th ICML*, 97, 5133–5141.

ARTÍCULO Mocanu, D. C., Mocanu, E., Stone, P., Nguyen, P. H., Gibescu, M., & Liotta, A. (2018). Scalable training of artificial neural networks with adaptive sparse connectivity inspired by network science. *Nature Communications*, 9, 2383.


CASO 1: COMPARANDO MODELOS

Semilla y rendimiento no correlacionan



CASO 1: COMPARANDO MODELOS

Probabilidad de equivocarse



P(confundir el orden)

N	Bootstrap	Monte Carlo
N=1	29%	48%
N=2	20%	31%
N=3	17%	20%
N=4	16%	14%
N=5	15%	10%

CASO 2: MEJORANDO MODELOS

SparseMLP

Estudios de Ablación

¿Qué son?




Búsqueda iterativa.

¿Cómo medimos los efectos de la varianza?:
Experimento factorial

epsilon	10	800	800	800
	20	800	800	800
	40	800	800	800
		1e-4	1e-3	1e-2
		learning rate		

$$9 \times 800 = \mathbf{7200}.$$


Estudios de ablación: ¿llegamos donde queremos?



CASO 2: MEJORANDO MODELOS

SparseMLP

Estudios de ablación: ¿Interacción $E \times L$?



ANOVA de medidas repetidas ($E \times L$ intra-sujeto)

Fuente	gl	F	p	η^2
E	2	93.825	<1e-16	32.0%
L	2	66.282	<1e-16	20.9%
E x L	4	73.415	<1e-16	46.0%

El peso de cada factor se mide, no se supone: puede ser decisivo o casi nulo ($\eta^2 \approx 0$), y depende del modelo. **No se sabe a priori.**

CASO 3: ¿MÁS FUENTES DE ALEATORIEDAD?


Variando solo la inicialización



Cada punto, una semilla de inicialización distinta.

CASO 3: ¿MÁS FUENTES DE ALEATORIEDAD?


Variando dos factores de aleatorización




Inicialización $\times$ orden $\rightarrow 35 \times 35 = 1225$ entrenamientos.

CASO 3: ¿MÁS FUENTES DE ALEATORIEDAD?


El mapa de la varianza




BourginMLP



SparseMLP




ContextDepNet

peor  mejor · $MSE \times 100$ · cada modelo a su escala · fila=init, col=orden

ARTÍCULO Peterson, J. C., Bourgin, D. D., Agrawal, M., Reichman, D., & Griffiths, T. L. (2021). Using large-scale experiments and machine learning to discover theories of human decision-making. *Science*, 372(6547), 1209–1214.

CASO 3: ¿MÁS FUENTES DE ALEATORIEDAD?

Cuánta varianza pone cada fuente



Descomposición de varianza (η^2 observado $\cdot$ init $\times$ orden)

Modelo	Fuente	gl	η^2 (% var)
BourginMLP	Inicialización	34	30.8%
	Orden	34	2.2%
	Interacción	1156	67.0%
SparseMLP	Inicialización	34	75.8%
	Orden	34	7.8%
	Interacción	1156	16.4%
ContextDepNet	Inicialización	34	98.7%
	Orden	34	0.16%
	Interacción	1156	1.1%

Descomposición **descriptiva** de la varianza (η^2): cuánto pesa cada fuente en la rejilla. Como el entrenamiento es determinista dadas las semillas (MSE bit-idéntico al repetir), la interacción **no es ruido: es estructura real**.

RECURSOS

Reprodúcelo tú mismo

Demos interactivas basadas en los datos **CPC18** así como los ejemplos de visión por computadora.

mlv-tools:



CONCLUSIÓN

¿Y ahora qué?

No dejarse llevar por el azar, pero sí podemos surfearlo (y reportarlo). Así mejoraremos la **reproducibilidad**, la **comparabilidad** y las fuentes de evidencia de **validez de las conclusiones** extraídas¹.

¹ Alicia, espero que así esté bien dicho.

mlv-tools:



Gracias



mlv-tools · (10.5281/zenodo.20268237)

e.heredia@umh.es

Que no te engañe el azar

Enrique Heredia-Aguado · Alejandro Rujano · David Valiente · Arturo Gil

Universidad Miguel Hernández de Elche (I3E) · UNED